

Predicción de Concentración de PM2.5 mediante Redes Neuronales Artificiales (MLP)

Tomas Saavedra Suazo

Universidad del Bío-Bío

30 de junio, 2026

Índice

- 1 Selección del problema
- 2 Análisis Descriptivo
- 3 Análisis Exploratorio (EDA)
- 4 Preprocesamiento
- 5 Modelado MLP
- 6 Overfitting y regularización
- 7 Evaluación del modelo
- 8 Función de predicción
- 9 Justificación económica
- 10 Conclusiones

1.- Selección del problema

Dataset

Beijing PM2.5 Air Quality — calidad del aire en Beijing, 2010–2014.

- **43.824 observaciones**
- **7 variables predictoras:** 6 numéricas + 1 categórica
- Variable objetivo: $\text{pm}_{2.5}$ (continua) → **problema de regresión**

Variable	Descripción
DEWP	Punto de rocío (°C)
TEMP	Temperatura (°C)
PRES	Presión atmosférica (hPa)
lws	Velocidad acumulada del viento (m/s)
ls	Horas acumuladas de nieve
lr	Horas acumuladas de lluvia
cbwd	Dirección combinada del viento (NE, NW, SE, cv)

2.- Análisis Descriptivo


Resumen general

- 43.824 filas $\times$ 13 columnas originales
- **2.067 valores faltantes** en pm2.5 ($\sim 4,7\%$)
- 0 duplicados
- Sin nulos en variables predictoras

Estadística descriptiva

- pm2.5: media 98,6, máx 994
- TEMP: -19°C a 42°C
- PRES: 991 a 1046 hPa

3.- Análisis Exploratorio de Datos




Histograma de pm2.5

3.-: Análisis Exploratorio de Datos



Correlación de variables meteorológicas

3.- Análisis Exploratorio de Datos



Boxplot de pm2.5 por categoría de cbwd

- Las categorías cv y SE muestran medianas más altas de PM2.5
- NW presenta los niveles más bajos → posible relación con dispersión de contaminantes

4.- Preprocesamiento

- 1 **Datos faltantes:** se eliminaron las filas con `pm2.5` nulo ($\sim 4,7\%$).
- 2 **Codificación:** `cbwd` (4 categorías) $\rightarrow$ *one-hot encoding* (`get_dummies, drop_first=True`)
- 3 **División de datos:** 70 % entrenamiento / 15 % validación / 15 % test
- 4 **Escalado:** `StandardScaler`, ajustado únicamente con el conjunto de entrenamiento
- 5 **Transformación del target:** $\log_{1p}(\text{pm2.5})$

5.- Arquitectura del modelo base

- Red **MLP secuencial** (Keras Sequential API)
- 2 capas ocultas: 124 y 64 neuronas, activación ReLU
- Capa de salida: 1 neurona, activación lineal (regresión)
- Optimizador: Adam (`learning_rate=0.001`)
- Función de pérdida: MSE — Métrica adicional: MAE
- 100 épocas, `batch_size=32`

5.- Búsqueda de hiperparámetros


Optimización Bayesiana con Keras Tuner (30 combinaciones evaluadas)

Hiperparámetro	Espacio de búsqueda
N° de capas ocultas	1 a 4
Neuronas iniciales	32, 64, 128, 256
Activación	ReLU, Tanh, ELU
Learning rate	0.01, 0.001, 0.0001

Mejor combinación encontrada:


- 2 capas ocultas, neuronas: [256, 153]
- Activación: **ELU**
- Learning rate: **0.001**
- Regularización aplicada: **Early Stopping** (patience=4, detenido en época 64)

6.- Detección de overfitting



Modelo Base

Criterio 5: Detección de overfitting



Modelo Optimizado

6.- Análisis del overfitting

Análisis

- El **gap** entre entrenamiento y validación al final del entrenamiento es similar en ambos modelos ($\approx 0,045-0,047$ MSE, escala log).
- El gap es **leve y estable**; no aumenta con las épocas, lo que indica un **overfitting leve y aceptable**.
- Se aplicó **Early Stopping** como medida preventiva.
- No se incorporaron técnicas adicionales de regularización (Dropout o L2), debido a que el sobreajuste observado no era significativo.

7.- Evaluación y comparación de modelos

Modelo	RMSE	MAE	R ²
Regresión Lineal	82,77	52,40	0,191
MLP Base	73,08	47,39	0,369
MLP Optimizado	74,62	47,12	0,343

- Ambos MLP superan claramente a la regresión lineal → la red captura relaciones no lineales relevantes
- El **MLP Base** obtiene mejor RMSE y R²
- Se selecciona el **MLP Base** como modelo final por su mejor desempeño global y menor complejidad

8.- Función de predicción (Funcion.py)

`prediccion(observacion, modelo_path, scaler_path, columnas_path)`

- 1 Recibe una observación nueva
- 2 Codifica `cbwd` (*one-hot*) y alinea columnas con `reindex`
- 3 Aplica el mismo `scaler` ajustado en el entrenamiento
- 4 Predice con el modelo guardado y revierte `log1p` con `expm1`
- 5 Clasifica el resultado según el Índice de Calidad del Aire (ICAP)

Categoría	Rango PM2.5 ($\mu\text{g}/\text{m}^3$)
Bueno	0 – 50
Regular (Alerta Temprana)	51 – 79
Alerta	80 – 109
Preemergencia	110 – 169
Emergencia	Más de 170

8.- Demostración en vivo

Predicción (Tutorial.ipynb)

Ejemplo: día frío, viento fuerte del NW

- Entrada: DEWP=-10, TEMP=-3, PRES=1025, Iws=35.5, cbwd='NW'
- Salida esperada: PM2.5 estimado + categoría

9.- Estimación de valor del proyecto

- Total de horas invertidas: **19,5 horas** (EDA, preprocesamiento, modelado, función, documentación)
- Tarifa de referencia: **CLP \$10.000/hora** (mercado Data Scientist junior)
- **Valor estimado del proyecto: CLP \$195.000**

Justificado en detalle en `Precio.txt`, considerando complejidad técnica: dataset de gran tamaño, transformación logarítmica del target, búsqueda bayesiana de hiperparámetros y entrega de programa reproducible.

- El modelo MLP supera ampliamente a una regresión lineal base
- El overfitting detectado es leve y fue manejado con Early Stopping
- Se entregó una función de predicción, documentada y con interpretación práctica.

¡Gracias!